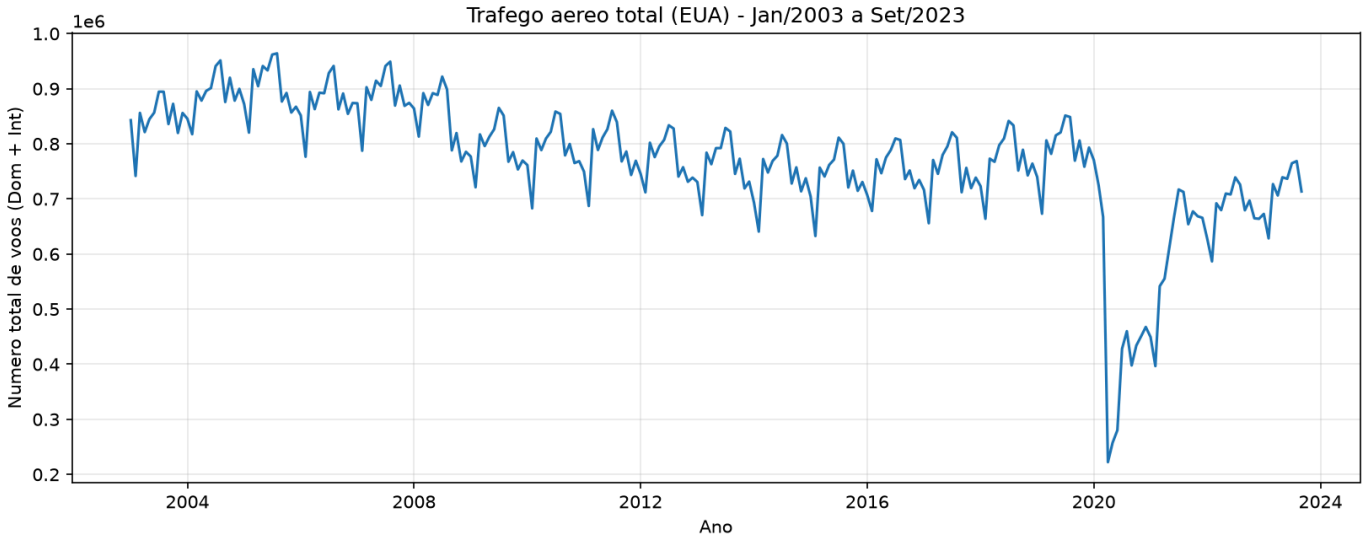
Atividade 1: Linear Regression

IA048 - Aprendizado de Máquina Turma A - 2° Semestre de 2026 Prof. Dr. Levy Boccato Alunos: Guilherme Braga do Vale | Omar Martín Gálvez Chachayma RA: 300875 | 300896

A — Série Temporal Completa

A série analisada corresponde ao número total de voos mensais (domésticos + internacionais) nos EUA, entre janeiro de 2003 e setembro de 2023 (249 amostras).

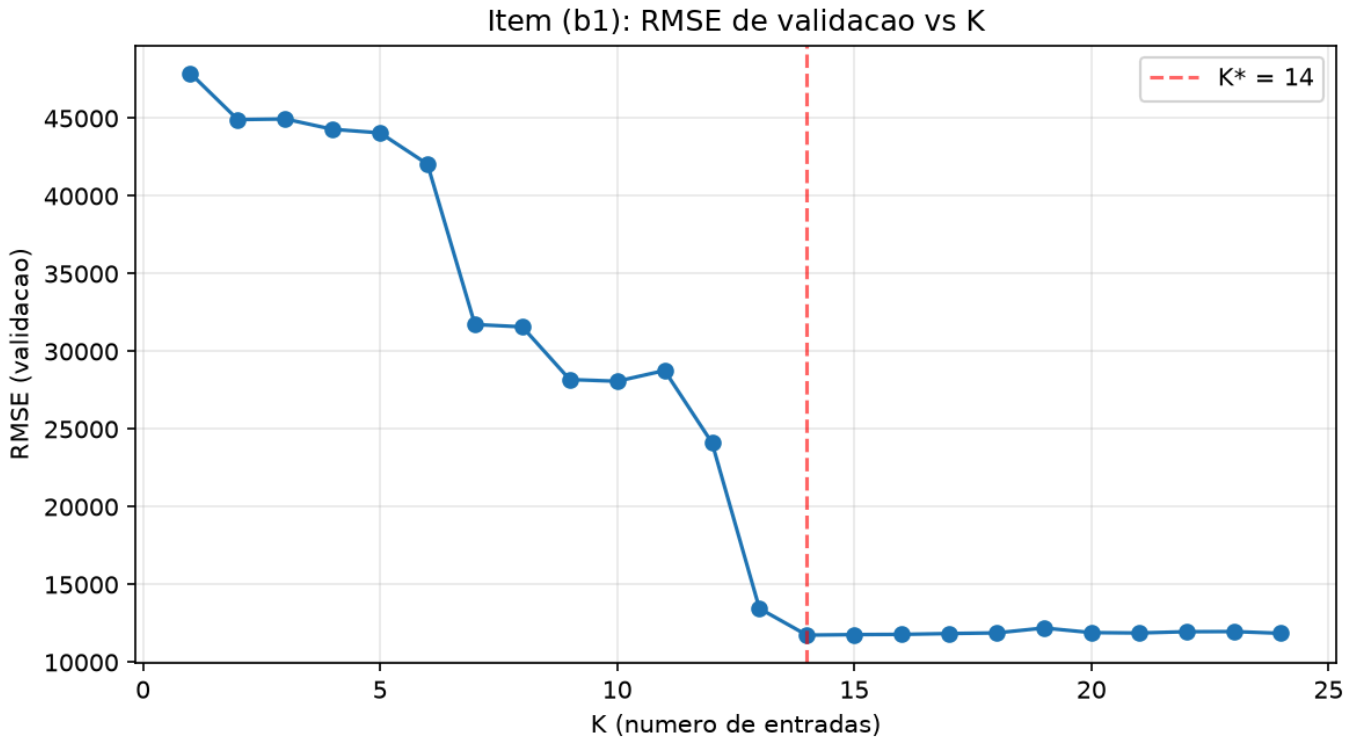


A inspeção visual confirma as três faixas de comportamento apontadas no enunciado:

- **Jan/2003 – Ago/2008:** recuperação pós-11/09/2001 e crescimento orgânico do tráfego aéreo, num período de expansão econômica anterior à crise financeira.
- **Set/2008 – Dez/2019:** o colapso do Lehman Brothers (set/2008) e a crise financeira global de 2008–2009 reduzem drasticamente a demanda por voos; a partir daí observa-se uma retomada gradual, com crescimento sazonal estável até o final de 2019.
- **Jan/2020 – Set/2023:** a pandemia de COVID-19 (com restrições generalizadas a partir de mar/2020) provoca uma queda abrupta e sem precedentes no tráfego aéreo, seguida de uma recuperação lenta e apenas parcial até o fim da amostra.

B1 — Seleção de K (RMSE de validação)

Divisão adotada: de acordo com o enunciado a divisão fora realizada de modo a compôr um único bloco (2003–2019) para realização do treinamento e validação. Assim, fora necessária definir uma subdivisão interna. Optou-se por uma separação cronológica: treinamento em 2003–2016 e validação interna em 2017–2019, usada exclusivamente para a escolha de K.

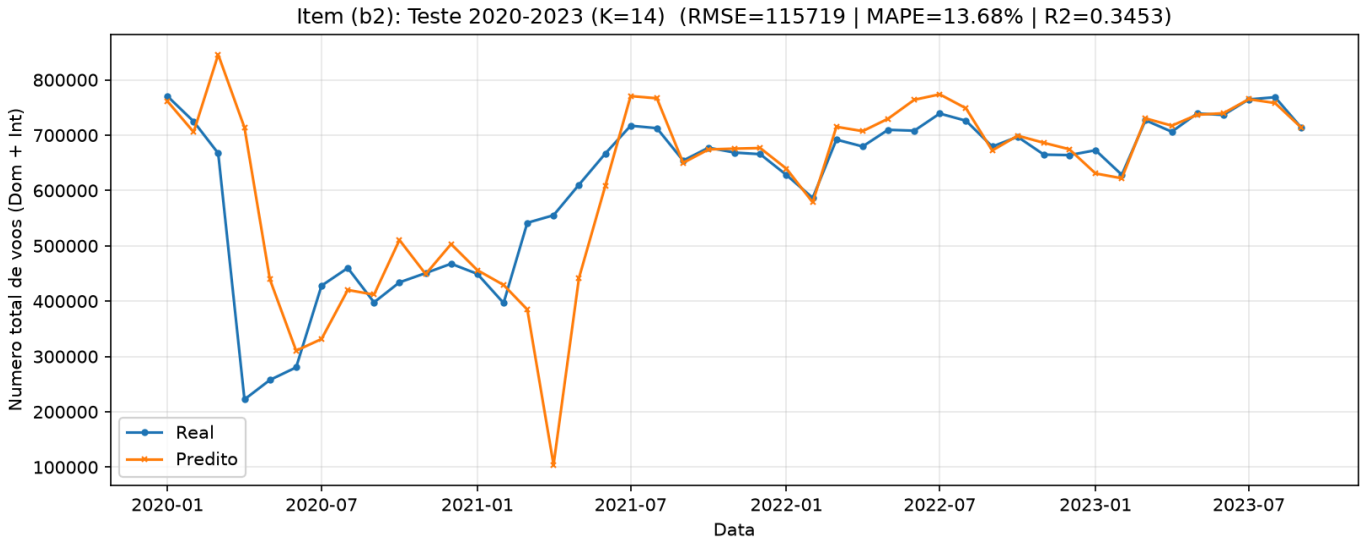


Grandeza	Valor
Faixa de treinamento	2003-01 a 2016-12
Faixa de validação	2017-01 a 2019-12
K* (melhor K)	**14**
RMSE de validação em K*	11.743,7

A curva apresenta uma queda acentuada entre K≈7 e K≈13, estabilizando-se a partir de K≈14. Esse comportamento é consistente com a hipótese de que o preditor só consegue capturar a sazonalidade anual do tráfego aéreo quando a janela de entrada cobre ao menos um ciclo completo de 12 meses; para K abaixo disso, o modelo carece de informação sobre o mesmo mês do ano anterior.

B2 — Teste no período 2020–2023

Modelo final reajustado com todo o bloco 2003–2019 (treino + validação), usando K=14, e avaliado no conjunto de teste completo (2020–2023).

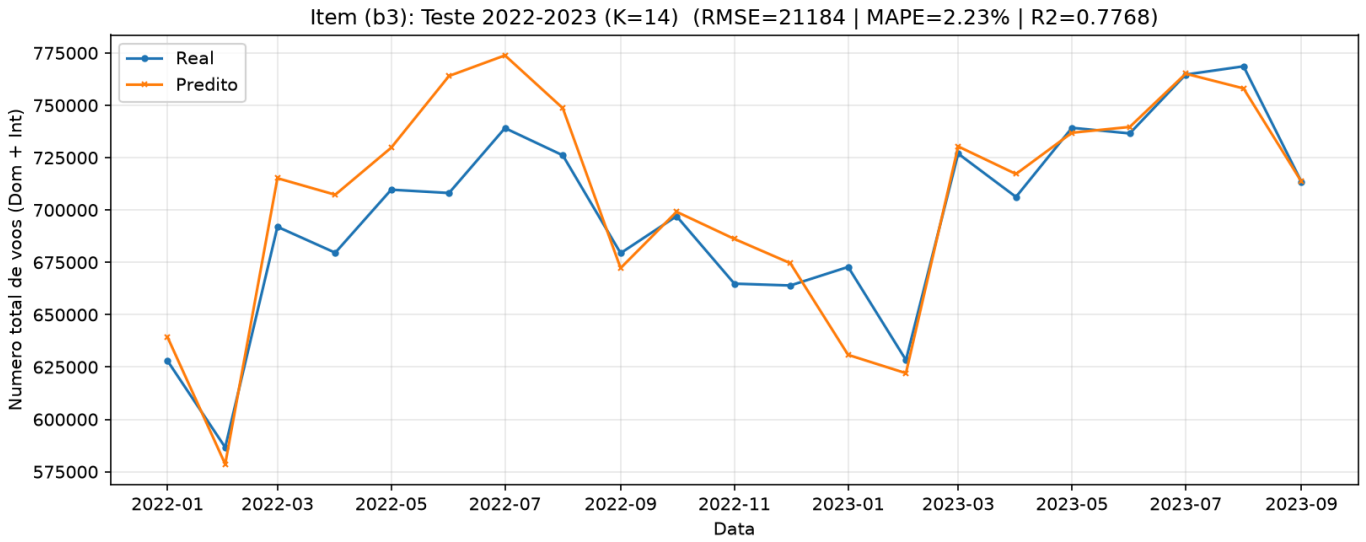


Métrica	Valor
n (amostras de teste)	45
RMSE	115.719,4
MAPE	13,68%
R^2	0,3453

O desempenho é consideravelmente pior do que o observado na validação. O gráfico mostra que a previsão reverbera o colapso real com um atraso de K meses, comportamento esse já esperado, dado que às entradas são valores reais defasados, não previsões recursivas. Como o modelo foi ajustado exclusivamente com dados anteriores à pandemia, ele não tem como antecipar um choque estrutural sem precedentes na série de treinamento, o que explica o R^2 baixo e o MAPE elevado nesse conjunto.

B3 — Teste restrito a 2022–2023

Mesmo modelo do item B2 (K=14, ajustado em 2003–2019), avaliado apenas nos dois últimos anos do conjunto de teste.



Métrica	Valor
n (amostras de teste)	21
RMSE	21.184,4
MAPE	2,23%
R^2	0,7768

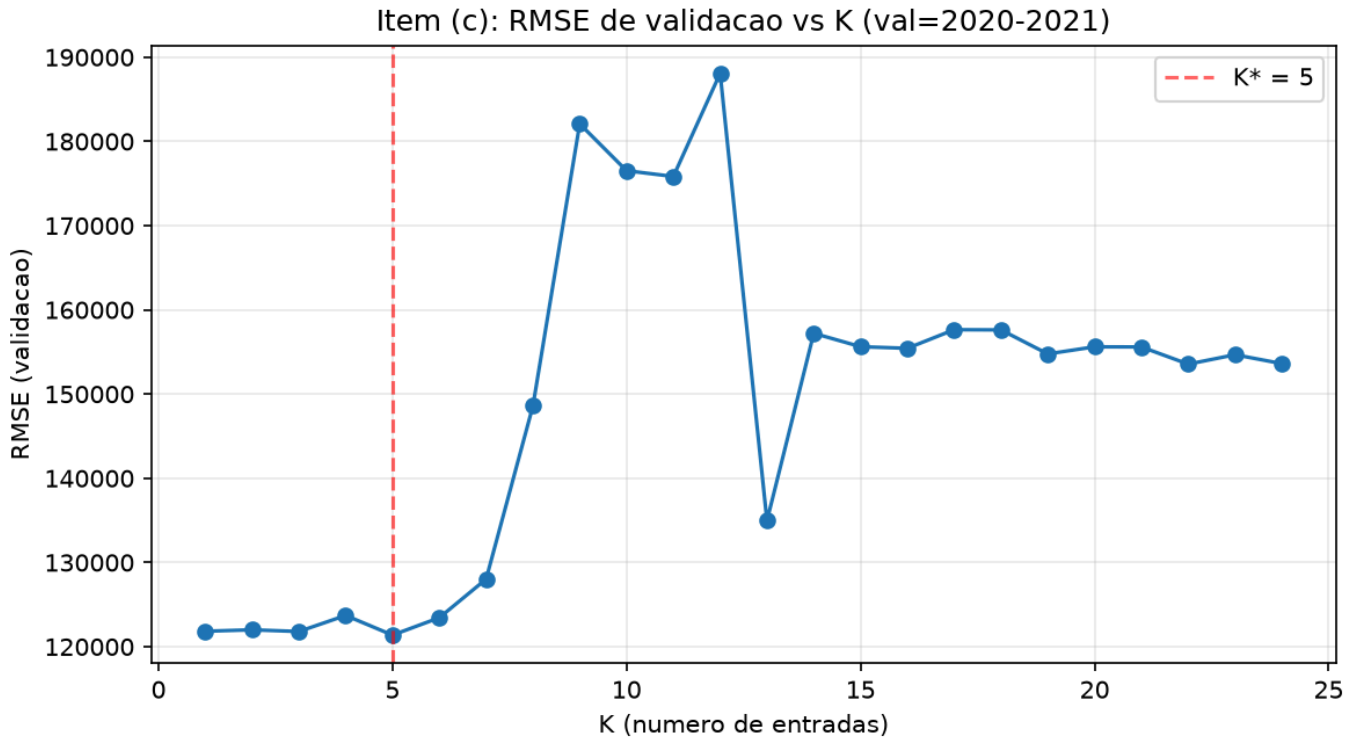
B2 vs B3 — Comparação

Item	Período de teste	n	RMSE	MAPE	R^2
B2	2020-01 a 2023-09	45	115.719,4	13,68%	0,3453
B3	2022-01 a 2023-09	21	21.184,4	2,23%	0,7768

A melhora expressiva de B2 para B3 (RMSE cai para ~18% do valor original; R^2 sobe de 0,35 para 0,78) é consistente com a ideia de que, em 2022–2023, o tráfego aéreo já havia retomado um padrão sazonal mais regular, semelhante ao observado no período de treinamento. Ou seja, o mesmo modelo, ajustado inteiramente com dados pré-pandemia, volta a generalizar bem assim que a série se estabiliza em torno de um novo patamar, sem os saltos extremos característicos do início da pandemia.

C — Nova divisão: treino 2003–2019 | validação 2020–2021 | teste 2022–2023

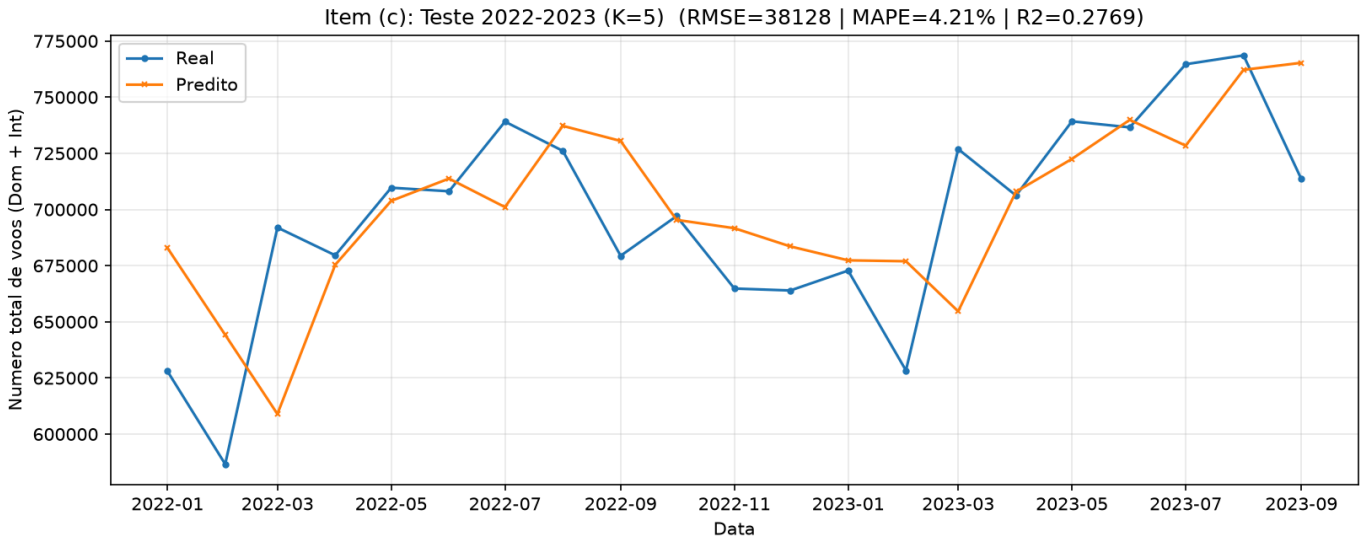
Aqui a validação passa a ser explicitamente o biênio 2020–2021 (o período mais volátil de toda a série, contendo o colapso e o início da recuperação).



Grandeza	Valor
Faixa de treinamento	2003-01 a 2019-12
Faixa de validação	2020-01 a 2021-12
K* (melhor K)	5
RMSE de validação em K*	121.371,6

Diferentemente da curva do item B1, esta não apresenta um formato monotônico e suave: fica relativamente baixa e estável para K=1–6, sobe abruptamente entre K≈7 e K≈12 (provavelmente porque, nesses lags, uma das entradas passa a coincidir com os meses de colapso mais profundo da pandemia), cai bruscamente em K≈13 e se estabiliza num patamar bem mais alto (~150 - 155 mil) a partir de K≈14. Isso sugere que o K* = 5 encontrado aqui não reflete necessariamente uma periodicidade sazonal genuína, mas sim uma tentativa do procedimento de minimizar o erro num período estruturalmente anômalo, evitando alinhamentos de lag desfavoráveis.

Modelo final reajustado com treino + validação combinados (2003–2021), K=5, avaliado no conjunto de teste (2022–2023):



Métrica	Valor
n (amostras de teste)	21
RMSE	38.127,7
MAPE	4,21%
R^2	0,2769

Comparação com o item B3 (mesmo período de teste, 2022–2023):

Item	Validação usada	K*	RMSE (teste)	MAPE (teste)	R^2 (teste)
B3	2017–2019 (regime "normal")	14	21.184,4	2,23%	0,7768
C	2020–2021 (regime de choque)	5	38.127,7	4,21%	0,2769

Mesmo realizando o treinamento com mais dados, incluindo o próprio período do choque, o modelo do item C generaliza com menos primor para 2022–2023 do que o modelo presenten no item B3. O que é consistente com a hipótese de que expor a seleção de K (e, em menor medida, o próprio ajuste do modelo) a um período estruturalmente anômalo prejudica a escolha do hiperparâmetro. Quando é selecionado K=5, não ocorre a captura o ciclo sazonal anual da forma que o K=14, escolhido a partir de um período marginalmente regular possui capacidade de captura, o que se reflete visualmente nos gráficos de teste. Com isso, o modelo presente B3 acompanha inclusive os vales sazonais de fevereiro, enquanto o modelo de C fica sistematicamente defasado em relação a picos e vales.